

AI tradicional

Desenvolvendo um modelo preditivo para
a copa do mundo



Eduardo Ventanilha
AI Engineer



Amanda Machado
AI Engineer

Como prever uma partida sem ser chute?

IA tradicional aplicada à Copa do Mundo

- Partir de uma pergunta simples: que informações ajudam a prever Brasil x Argentina?
- Traduzir esse raciocínio em dados, features, labels, treino, teste e predição.
- Encapsular o modelo como uma tool que um agente pode chamar e explicar.

pergunta humana

o que eu olharia antes de dar um palpite?

modelo tradicional

aprende padrões a partir do histórico

resposta útil

probabilidade, placar esperado e explicação

— ANTES DO ALGORITMO

Se você tivesse que prever Brasil x Argentina, o que olharia antes de dar um palpite?

Histórico, média de gols, fase recente, ranking, mando e jogos parecidos viram variáveis. O resultado real vira gabarito.

IA tradicional

- Calcula probabilidades usando histórico estruturado.
- Entrega classe, score, ranking ou previsão.
- É boa quando precisamos medir e auditar.

combinação

**modelo vira
tool**

IA generativa


- Conversa com o usuário e organiza a intenção.
- Explica a resposta e cria uma experiência.
- É boa como interface e orquestração.



— TRADUZINDO OS TERMOS

O nome técnico vem depois da intuição: cada partida vira uma linha de dados.

A partir daí, mantemos o mínimo técnico para a turma entender o notebook e a avaliação.



saída


probabilidade de vitória, empate,
derrota ou gols esperados

Contrato mental da aula: dados antes do jogo → modelo treinado → previsão mensurável.

— POR QUE AINDA IMPORTA

Quando a pergunta pede número, ranking, classe ou probabilidade, IA tradicional continua sendo a base.

A GenAI pode explicar a resposta, mas a probabilidade precisa vir de um cálculo testável.



No caso da Copa: a conversa pode ser generativa, mas o palpite calculado vem do modelo treinado.


— GENERALIZAÇÃO

O risco é decorar o passado. O objetivo é funcionar em partidas novas.

Depois de entender a ideia, damos os nomes técnicos: underfitting, generalização e overfitting.

Underfitting

simples demais

treino 

teste 

Não aprende nem os padrões básicos.

Ideal

generaliza

treino 

teste 

Captura tendência e ignora ruído.

Overfitting

decorou ruído

treino 

teste 

Parece perfeito no treino, falha no mundo real.

barras = desempenho relativo

— FAMÍLIAS DE APRENDIZADO

A prática usa aprendizado supervisionado: o histórico já tem o gabarito.

Os outros tipos aparecem para contexto, mas o foco da Session 2 é aprender com resposta correta.

Supervisionado

"estudar com gabarito"

- Tem resposta correta no histórico.
- Aprende a prever classe ou valor.
Ex. da aula: prever vitória, empate, derrota ou gols.

Não supervisionado

"organizar por semelhança"

- Não recebe respostas prontas.
- Descobre grupos, anomalias ou perfis.
- Ex.: agrupar estilos de seleções.

Por reforço

"aprender por tentativa e erro"

- Toma uma ação e recebe consequência.
- Maximiza recompensa ao longo do tempo.
- Ex.: estratégia de substituições simuladas.

— DUAS PERGUNTAS DA PRÁTICA

Não precisamos explicar todos os algoritmos. Primeiro escolhemos o tipo de resposta que queremos.

Classificação responde quem vence. Regressão responde quantos gols.




pergunta certa → tipo de modelo certo → métrica certa

— PRÁTICA 1

Cada linha representa uma partida. Cada coluna precisa ser uma informação conhecida antes do jogo.

Antes de treinar, o dado precisa virar uma tabela em que cada linha representa uma partida observável.



Regra de ouro Nenhuma feature pode usar informação que só seria conhecida depois do jogo.

Isso evita vazamento de dados e deixa a avaliação honesta.

— MODELAGEM

A simulação fica mais intuitiva quando separamos duas tarefas: resultado provável e gols esperados.

Esse é o mínimo técnico importante: classificação para classes; regressão para valores numéricos.

features antes do jogo

força relativa,
desempenho recente,
mando, fase, histórico e
diferença de gols

modelo de resultado

gera $P(\text{vitória})$, $P(\text{empate})$,
 $P(\text{derrota})$

modelo de gols

estima volume ofensivo para
cada lado

simulação

**Brasil 2 x 1
Argentina**

exemplo de saída: placar +
probabilidades +
explicação do modelo

— AVALIAÇÃO

Depois de prever, conferimos o placar dos acertos e erros.

Matriz de confusão é o nome técnico para organizar quando o modelo acertou e quando confundiu uma classe com outra.

		Detectado pelo modelo	
		Sim	Não
Real	Sim	Verdadeiro Positivo (VP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (VN)

Pergunta prática

Quando digo que um time vence, quantas vezes isso realmente acontece?

— AVALIAÇÃO

Depois de prever, olhamos onde o modelo acertou e onde confundiu as classes.

Como o desafio prevê três resultados, a matriz precisa mostrar vitória do mandante, empate e vitória do visitante.

Previsto pelo modelo

Real		Vitória mandante	Empate	Vitória visitante
	Vitória mandante	acertou mandante	confundiu com empate	confundiu com visitante
	Empate	confundiu com mandante	acertou empate	confundiu com visitante
	Vitória visitante	confundiu com mandante	confundiu com empate	acertou visitante

Como ler

Diagonal = acertos

Fora da diagonal = confusões

3 classes

0 empate

1 mandante

2 visitante

Pergunta prática: em quais resultados o modelo mais acerta?
Onde ele mais se confunde?

— MÉTRICAS

Para iniciantes, comece pela pergunta de negócio. Depois mostre o nome técnico.

Accuracy mede acerto geral; precision mede confiança quando o modelo prevê positivo; recall mede cobertura; F1 equilibra precision e recall.

Precision

Dos positivos previstos, quantos eram positivos de verdade?

$$VP / (VP + FP)$$

Recall

Dos positivos reais, quantos eu encontrei?

$$VP / (VP + FN)$$

F1-score

O equilíbrio entre precision e recall.


$$2 \times P \times R / (P + R)$$

Em previsão de partidas, F1 ajuda quando queremos equilíbrio: não basta acertar só favoritos.

— PONTE PARA AGENTES

O agente não precisa adivinhar a probabilidade. Ele chama uma tool preditiva.

A pessoa pergunta em linguagem natural; o agente organiza a pergunta, chama o modelo e traduz a resposta.



A separação de responsabilidades deixa o sistema testável: dados, modelo, tool e resposta podem ser validados em camadas.

— FECHAMENTO

Leve três ideias: dados, modelo e métrica.

Dados dizem o que sabemos antes do jogo; modelo aprende com o passado; métrica diz se dá para confiar.

Dados

o que sabemos antes
do jogo

Modelo

o que aprendemos
com o passado


Métrica

como sabemos se dá
para confiar

Workshop



Bônus Game



Avalie esta sessão!

Seu feedback é fundamental para
evoluirmos a experiência do
Oracle Data Deep Dive



ORACLE